Universidade do Minho
Departamento de Informática
Licenciatura em Ciência de Dados

Sistemas Conexionistas para Aprendizagem Automática
3º Ano, 1º Semestre
Ano letivo 2026/2027

Enunciado Prático nº 1
23 de setembro de 2026

Tema

Manipulação de dados categóricos.

Enunciado

Dados categóricos são, no geral, mais complexos de lidar do que dados numéricos. De facto, são vários os algoritmos de *Machine Learning* que exigem que o seu *input* seja numérico, sendo necessária a aplicação de técnicas que transformem esses mesmos atributos. Duas das técnicas mais utilizadas são o *one-hot encoding* e o *label encoding*. A primeira, utilizada essencialmente quando não existe uma ordenação entre as categorias, consiste na criação de novos atributos binários para cada chave única de um dado atributo não numérico (por exemplo, novos atributos binários para cada tipo de cozinha ou para cada género de filmes). A segunda, *label encoding*, consiste na criação de um *label* para cada chave única de um dado atributo não numérico ([Braga, Porto, Guimarães, Braga] para [0, 1, 2, 0]).

Tarefas

Esta ficha encontra-se dividida em duas partes distintas.

1. Na primeira parte desta ficha prática pretende-se que sejam instalados e criados ambientes virtuais para suportar os trabalhos práticos que serão realizados durante o semestre letivo;

2. Para a segunda parte da ficha prática, devem descarregar o *dataset* disponível na blackboard (*flights_dataset.csv*) que contém um conjunto de dados sobre vários voos, incluindo o ano, a hora de chegada, o atraso sofrido, a origem e o destino do voo, entre outros. Pretende-se assim que sejam realizadas as seguintes tarefas:

    - Analisar o *dataset* em relação ao número de registos e a cada um dos seus atributos, os seus valores e respetivos tipos;
    - Desenvolver o algoritmo correspondente à técnica de *label encoding*;
    - Utilizar a biblioteca *pandas*, em particular o método *get_dummies*, para aplicar a técnica de *one-hot encoding*;
    - Utilizar uma plataforma na *cloud* para executar o código produzido.

Como base para o desenvolvimento da ficha deixa-se o seguinte excerto de código:

```
import numpy as np
import pandas as pd

# Load the dataset to a variable called df
df = pd.read_csv('flights_dataset.csv')
```

```
# Print some dataset info
print(df.info())
print('——')

# Drop unwanted columns
df.drop(['hour','minute','tailnum'], 1, inplace=True)

# Infer objects type – did something happen?
df.infer_objects()

# Check and replace missing values with -99 (masking).
print(df.isnull().sum())
print('——')
df.fillna(-99, inplace=True)

# Checking the frequency distribution of categories within a feature.
print(df['dest'].unique())
print('Unique count: %d' %df['dest'].value_counts().count())
print('——')
print(df['dest'].value_counts())
print('——')

'''
Function to encode all non-(int/float) features in a dataframe.
For each column, if its dtype is neither int or float, get the list of unique values,
store the relation between the label and the integer that encodes it and apply it.
Return a labelled dataframe and a dictionary label to be able to restore the original value.
(8-10 lines - you may need an auxiliar function)
'''
def label_encoding(df):
    pass

'''
Function to decode what was previously encoded - get the original value!
(5-8 lines - you may need an auxiliar function)
'''
def label_decoding(df_labelled, label_dictionary):
    pass

df_labelled, label_dictionary = label_encoding(df)
print(df_labelled['dest'].unique())
print('Unique count after Label Encoding: %d' %df_labelled['dest'].value_counts().count())

df_labelled_decoded = label_decoding(df_labelled, label_dictionary)
print(df_labelled_decoded['dest'].unique())
print('Unique count after dec.: %d' %df_labelled_decoded['dest'].value_counts().count())
print('——')

'''
Use a pandas' function to apply one-hot encoding to the origin column (one line).
'''
print('Unique Origin:', df['origin'].unique())
print(df.columns.values)
df_pandas_ohe = TODO
print(df_pandas_ohe.head())
```